12. Actividad 5 — Anonimización (anonymization)

El área de dirección solicita información estadística. No necesita conocer los clientes individualmente.El objetivo es generar información agregada y reducir el riesgo de reidentificación.

12.1 Generalizar la edad

```sql
/* 12. Actividad 5 — Anonimización (anonymization) */
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+'
    END AS rango_edad,
    COUNT(*) AS total
FROM clientes
GROUP BY 1;
```

Data Output | Messages | Notifications

	rango_edad text	total bigint
1	31-45	4
2	46+	1

12.2 Generalizar la región

```sql
/* 12.2 Generalizar la región */
SELECT
    LEFT(codigo_postal, 2) AS region,
    COUNT(*) AS total
FROM clientes
GROUP BY 1;
```

Data Output | Messages | Notifications

	region text	total bigint
1	82	1
2	80	3
3	81	1

12.3 Combinar atributos

```sql
/*12.3 Combinar atributos*/
SELECT
    CASE
        WHEN edad BETWEEN 18 AND 30 THEN '18-30'
        WHEN edad BETWEEN 31 AND 45 THEN '31-45'
        ELSE '46+'
    END AS rango_edad,

LEFT(codigo_postal, 2) AS region,
COUNT(*) AS total

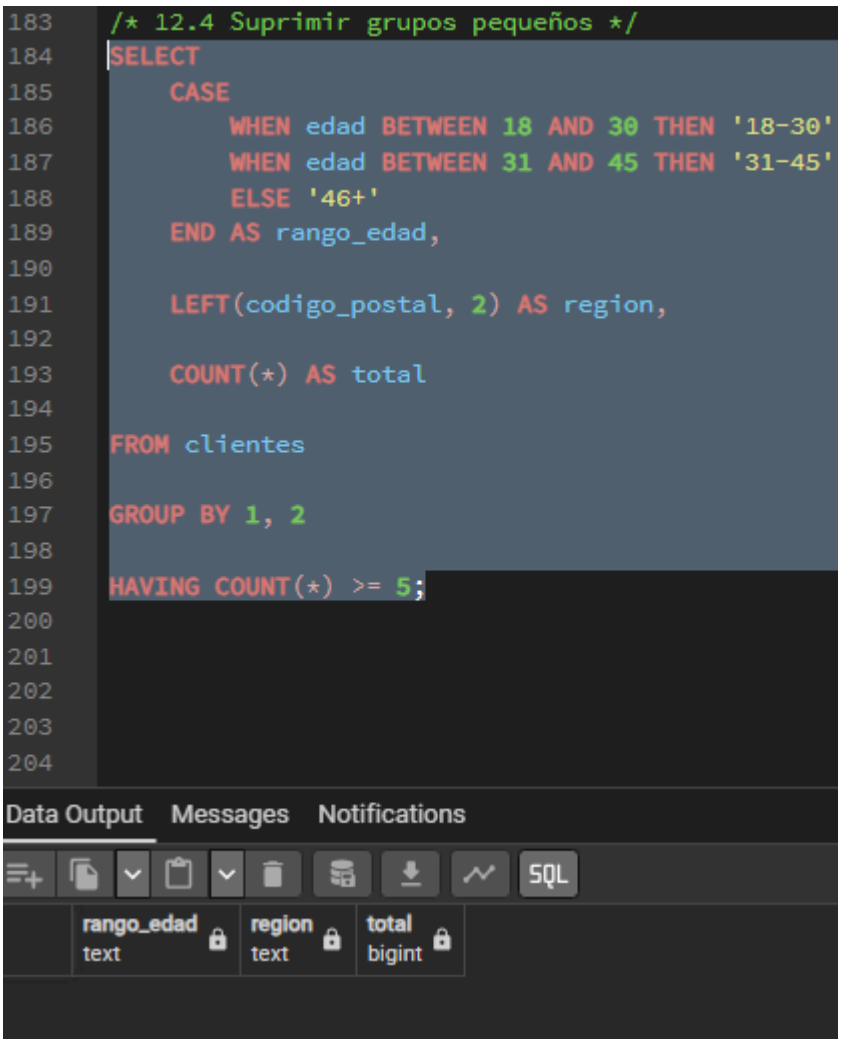
FROM clientes

GROUP BY 1, 2;
```

Data Output | Messages | Notifications

	rango_edad text	region text	total bigint
1	31-45	81	1
2	46+	82	1
3	31-45	80	3

12.4 Suprimir grupos pequeños



Analizar el resultado obtenido en la actividad anterior.

Responder:

¿Qué identificadores directos fueron eliminados?

Los resultados no contienen nombre, correo, telefono, rfc ni id, porque las consultas solo devuelven conteos agrupados.

¿Qué cuasi-identificadores permanecen?

rango_edad, derivado de edad.
region, derivada de codigo_postal.

¿Qué combinaciones de atributos podrían reducir el anonimato?

rango_edad + region (consulta 3): produce grupos de tamaño 1, y esa combinación es suficiente para aislar a una persona.
Combinar la salida con otros datos: ciudad, fecha_alta o el CP completo harían los grupos aún más pequeños.

¿Qué sucede cuando un grupo contiene pocos registros?

Con grupos muy pequeños (2 o 3) el riesgo sigue siendo alto, y además puede haber divulgación de atributos: si todas las personas del grupo comparten una característica, se conoce el dato de cualquiera de ellas sin identificar por completo. Lo que falla es el volumen de datos, no la técnica.

¿Qué atributos debería generalizarse?

edad: rangos más amplios (por ejemplo 18-45 y 46+) o por décadas.
codigo_postal: solo el primer dígito, o pasar a municipio o estado.
ciudad: agrupar por zona o por estado.
fecha_alta: reducirla a año, o a trimestre o año.

¿Qué información debería suprimirse?

Nombre, correo, telefono, rfc e id (o su sustitución por tokens separados de la llave). los grupos con menos de k personas deben suprimirse o fusionarse con otros. La cláusula HAVING COUNT(*) >= k hace exactamente esto.

¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué?

El conjunto presenta un riesgo de reidentificación reducido bajo ciertos supuestos (k ≥ 5, generalización aplicada)”, y en este ejemplo ni siquiera eso se cumple, salvo en la consulta 4, que suprime todo.